Data Analysis with Python

How to start programming without being a computer scientist

Martina Kienberger

VNiVERSiDAD D SALAMANCA
CAMPUS DE EXCELENCIA INTERNACIONAL

800 AÑOS
1218 - 2018

universität wien

Contenidos

1. Python, un lenguaje de programación
2. Empezando a trabajar con Python
3. Un ejemplo: Mi proyecto de investigación
4. Algunas estrategias de aprendizaje

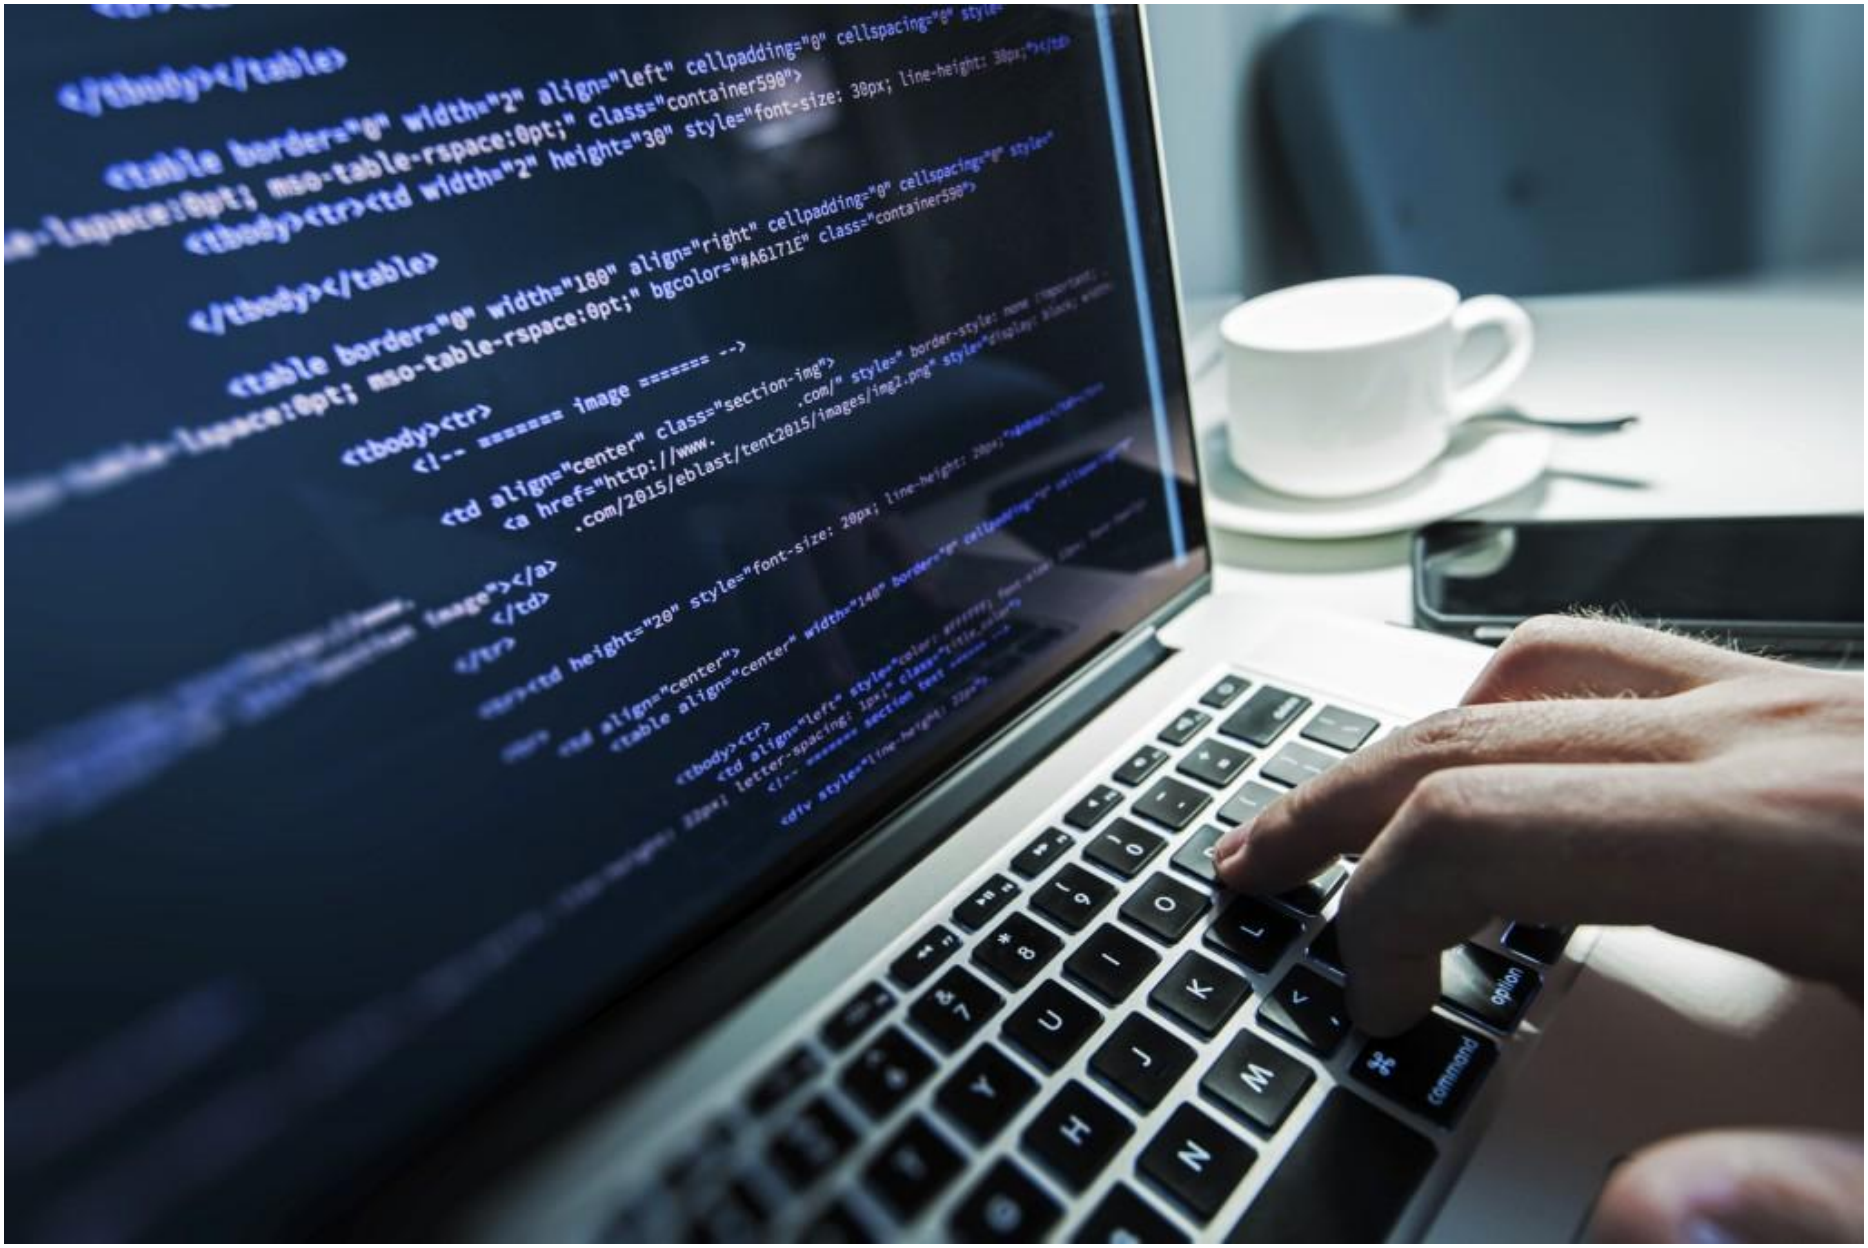

Analyzing strategy use

Dividing subgroups

In [9]:
```
A2 = data[data.Grupo == 'A2']
```

In [10]:
```
B2 = data[data.Grupo == 'B2']
```

Group A2

In [11]:
```
print(r'Participants: ' + str(len(A2.ID_alumno.unique()))+'\n'+
      r'TN + Online-Survey: ' + str(len(A2[A2.Encuesta == 1].ID_alumno.unique()))+'\n'+
      r'TN - Online-Survey: ' + str(len(A2[A2.Encuesta == 2].ID_alumno.unique()))+'\n'+
      r'TN ? Online-Survey: ' + str(len(A2[A2.Encuesta == 0].ID_alumno.unique())))
```

```
Participants: 28
TN + Online-Survey: 6
TN - Online-Survey: 18
TN ? Online-Survey: 4
```

Group A2 consists of 28 participants. 6 had taken part in the online survey on strategy use, 18 had not, 4 didn't indicate whether they had participated or not.

Words indicated as "new" (A2)

In [12]:
```
len(A2.Palabra.unique())
```

Out[12]: 47

Learners wrote down 47 different words as "new" for them. When transferring data from the task sheets to Excel, we corrected orthographic errors. The words were taken from the textbook text in their respective spellings of the original text (even if learners indicated some other form, such as infinitive, instead) In the case of the word "bietet ... an", there were two forms accepted, "bietet" and "bietet an", according to the learners, who sometimes did, sometimes did not recognize the word as a separable verb.

In [13]:
```
A2.Palabra.value_counts(ascending = True).plot(kind = 'barh', figsize = (5,12));
```

1. Python, un lenguaje de programación

1. Python, un lenguaje de programación

In [18]:
```
A2.ID_alumno.value_counts().sort_index()
```

1. Python, un lenguaje de programación

In [18]: **A2**.**ID_alumno**.value_counts().sort_index()

variable definida anteriormente (datos de mi tabla Excel)

columna en la tabla Excel

nombres propios

1. Python, un lenguaje de programación

In [18]: `A2.ID_alumno.value_counts().sort_index()`

- `A2` — variable definida anteriormente (datos de mi tabla Excel)
- `ID_alumno` — columna en la tabla Excel
- `value_counts()`, `sort_index()` — instrucciones

vocabulario

nombres propios

1. Python, un lenguaje de programación

In [18]: `A2.ID_alumno.value_counts().sort_index()`

- `A2` — variable definida anteriormente (datos de mi tabla Excel)
- `ID_alumno` — columna en la tabla Excel
- `value_counts()`, `sort_index()` — instrucciones

vocabulario

nombres propios

elementos de conexión y reglas para su uso, el orden de las partes

gramática

```
In [18]: A2.ID_alumno.value_counts().sort_index()

Out[18]: 1     27
         2     13
         3     10
         4      4
         5      5
         6     20
         7     19
         8     19
         10    10
         11    10
         12    20
         13    13
         14     7
         15    14
         16    16
         17    11
         18     9
         19    15
         20     9
         21    17
         22    10
         23    13
         24     9
         25     5
         26    20
         27    14
         28    12
         29    20
         Name: ID_alumno, dtype: int64
```

1. Python, un lenguaje de programación

In [26]:

```
for val in CTA2_2.index:
    for col in CTA2_2.columns:
        if CTA2_2.loc[val,col]!=0:
            CTA2.loc[val,col] = CTA2.loc[val,col]+ CTA2_2.loc[val,col]
```

1. Python, un lenguaje de programación

In [26]:

```
for val in CTA2_2.index:
    for col in CTA2_2.columns:
        if CTA2_2.loc[val,col] != 0:
            CTA2.loc[val,col] = CTA2.loc[val,col] + CTA2_2.loc[val,col]
```

In [34]:
```
fig = plt.figure(figsize=(10,10))
ax1 = fig.add_subplot(111)

ax1.scatter(R[:,0],R[:,1], s = 9)
for i in range(R.shape[0]):
    ax1.text(R[i,0],R[i,1], str(CTA2.index[:-1][i]), fontsize=12 )
for i in range(C.shape[0]):
    ax1.arrow(0,0,C[i,0],C[i,1])
    #ax1.scatter(C[i,0],C[i,1])
    ax1.text(C[i,0],C[i,1],CTA2.columns[:-1][i],fontsize=20)

plt.show()
```

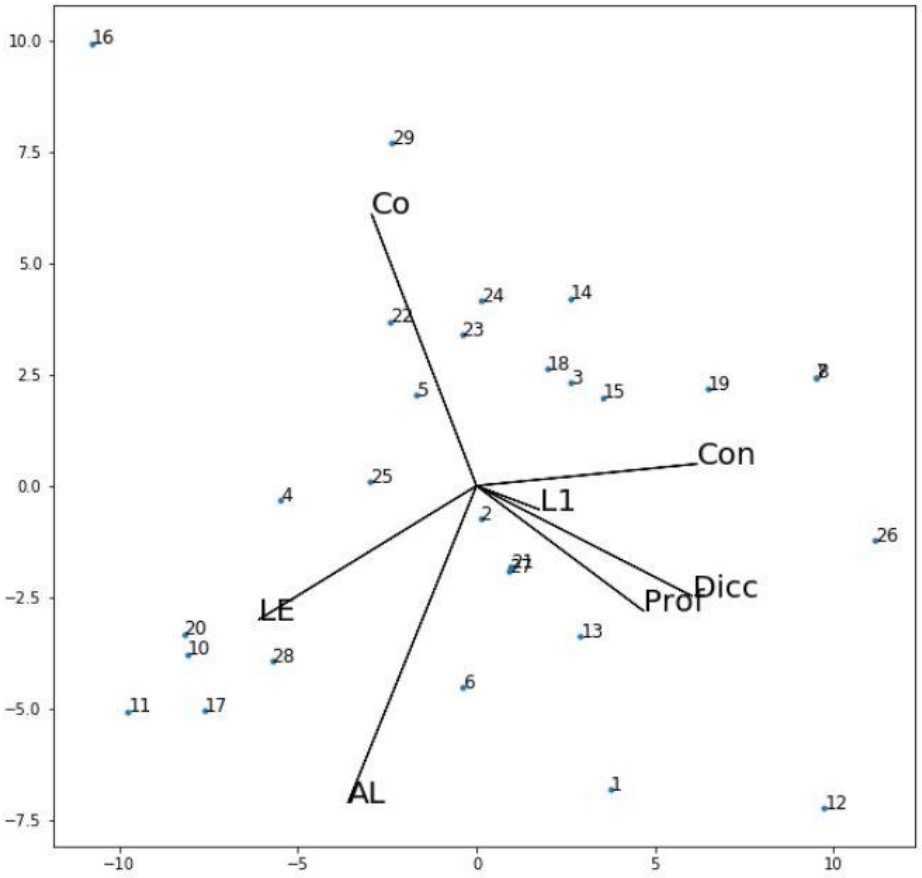

2. Empezando a trabajar con Python



2. Empezando a trabajar con Python

- Instalación

2. Empezando a trabajar con Python

- Instalación

- Un entorno para programar


jupyter
Logout
Files
Running
Clusters
Select items to perform actions on them.
Upload
New
0
/
Name
Last Modified
Anderes
vor ein paar Sekunden
Code
vor 15 Tagen
Code_Stan
vor 8 Monaten
Code_Voc
vor 3 Tagen
Daten
vor 5 Tagen

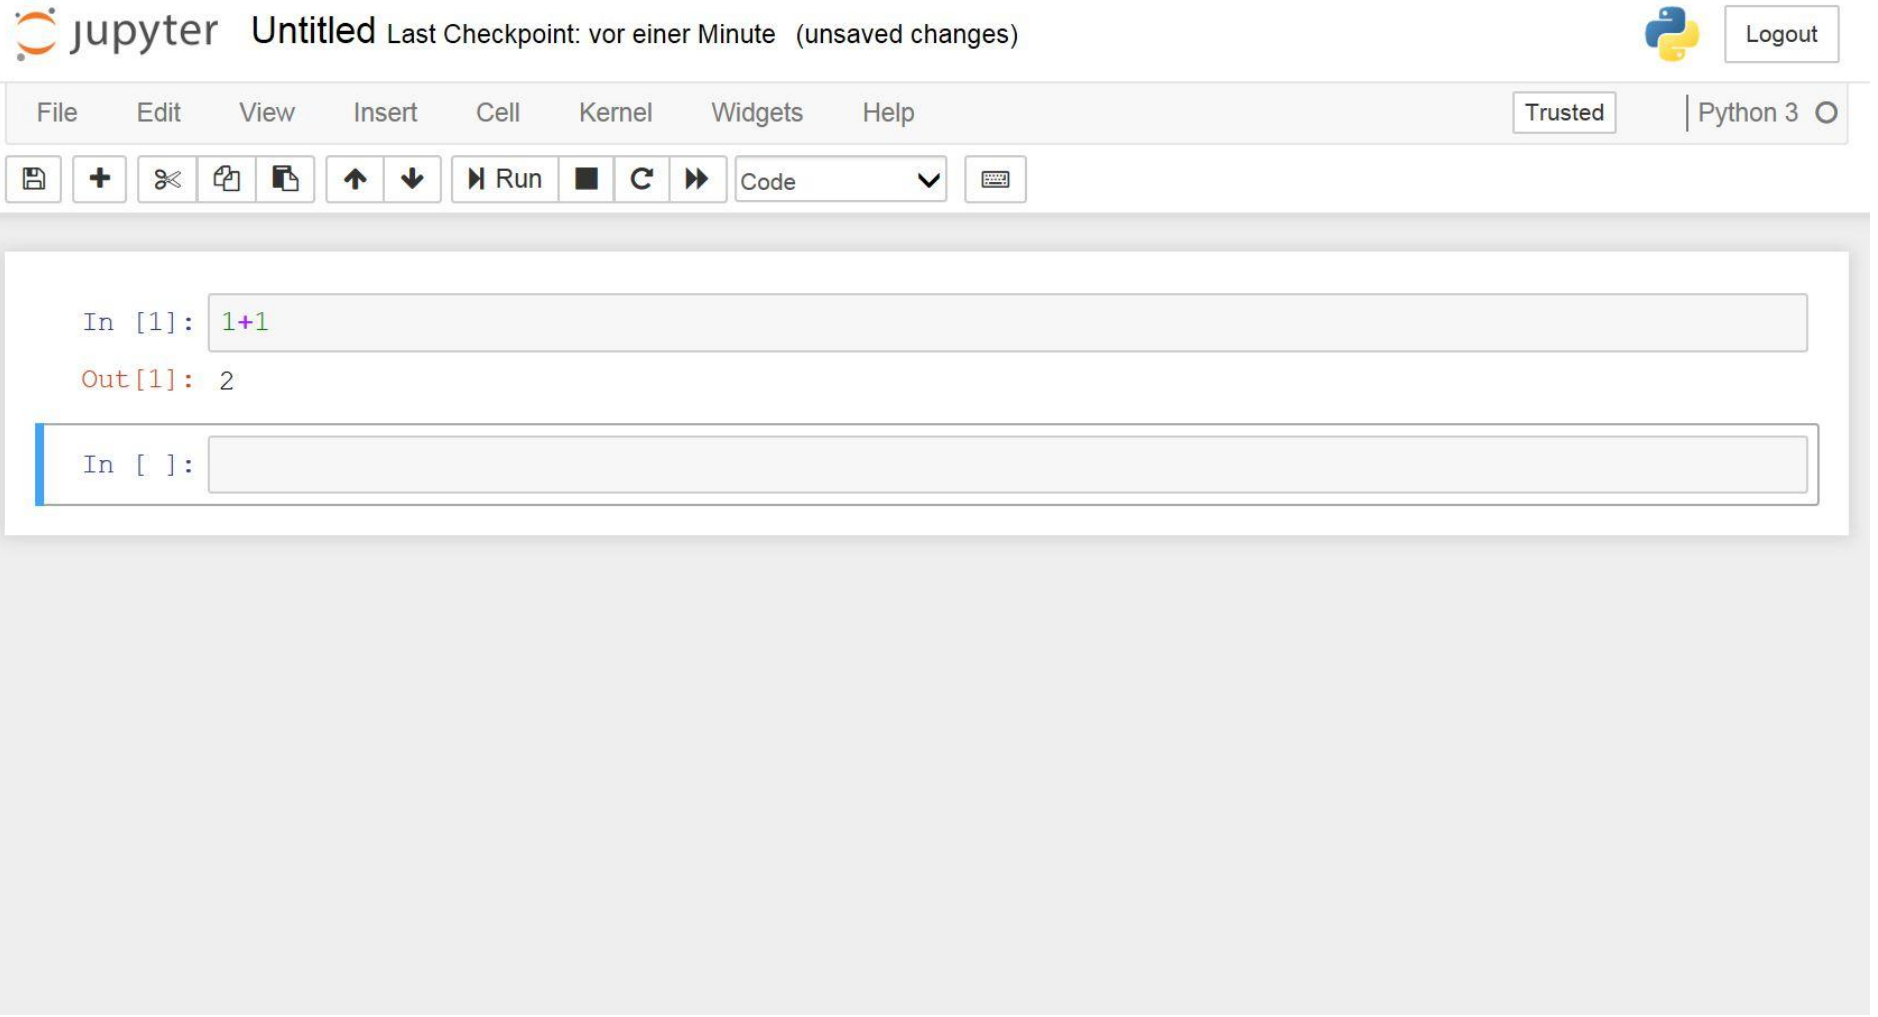
jupyter Untitled Last Checkpoint: vor einer Minute (unsaved changes)
Logout
File Edit View Insert Cell Kernel Widgets Help
Trusted
Python 3
Run
Code
In [1]: 1+1
Out[1]: 2
In [ ]:

jupyter Datenanalyse_Voc_Valencia Last Checkpoint: 18.09.2018 (autosaved) Logout

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

Run Markdown

Vorbereitung - Datenreinigung

In [1]:
```
import pandas as pd
import numpy as np
from biofes import biplot
from sklearn.utils.extmath import randomized_svd
from sklearn.cluster import KMeans, AgglomerativeClustering
from adjustText import adjust_text
% pylab inline
```

```
Populating the interactive namespace from numpy and matplotlib
```

In [2]:
```
Rohdaten = pd.read_excel('D:\Daten\DISS\Daten\Valencia.xlsx')
```

In [3]:
```
Rohdaten.head(3)
```

Out[3]:

	Grupo	ID_alumno	Encuesta	Palabra	Estrategia_1	Estrategia_2	Estrategia_Esp_1	Estrategia_Esp_2	Comentario
0	A2	1	1	lebendiger	AL	NaN	Comp	NaN	NaN
1	A2	1	1	langen	Con	NaN	NaN	NaN	NaN
2	A2	1	1	eigene	Dicc	NaN	NaN	NaN	NaN

jupyter Datenanalyse_Voc_Valencia Last Checkpoint: 18.09.2018 (autosaved)

Logout

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

Run Markdown

```
28    12
29    20
Name: ID_alumno, dtype: int64
```

In [19]:
```
A2.ID_alumno.value_counts().plot(kind = 'hist',
                                 bins = 10);
```

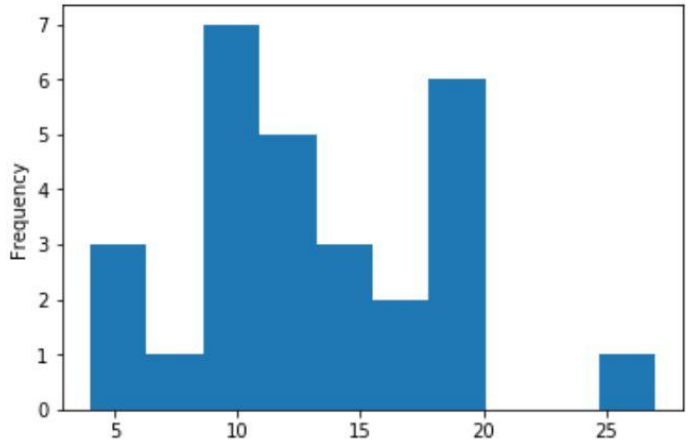

Das Histogramm zeigt die Frequenz der notierten Wortanzahl pro TN - keine Normalverteilung in diesem Fall.

2. Empezando a trabajar con Python

- Instalación

- Un entorno para programar

- Guardar y compartir los resultados

Search or jump to... / Pull requests Issues Marketplace Explore

Set your status

Martina Kienberger

martinakienberger

PRO

Teacher and researcher at the University of Salamanca, phd student at the University of Viena

Salamanca

http://diarium.usal.es/martinaki...

Edit

Overview Repositories 4 Projects 0 Stars 0 Followers 2 Following 0

Popular repositories

Customize your pins

Charla_PyConES2018

Presentación "Estrategias de comprensión con y para Python" (charla en la PyConES 2018 en Málaga)

★ 3

Strategienanalyse_Voc

Research project

Jupyter Notebook

PyConES-2018-data

Forked from python-spain/PyConES-2018-data

All known documentation about PyConES2018 (Slides, PDF, Repos)

38 contributions in the last year

Contribution settings

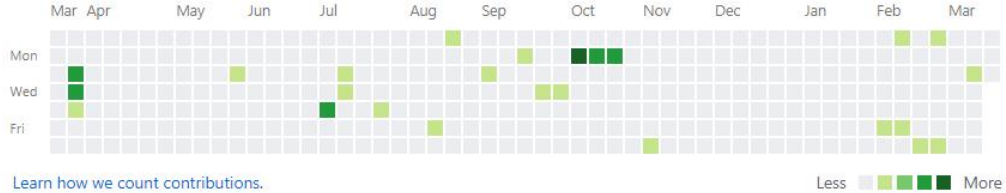

Learn how we count contributions.

Less More

Branch: master ▾ Strategienanalyse_Voc / Datenanalyse_Voc_Valencia.ipynb Find file Copy path

martinakienberger Wortlisten, Details Granada 6b9f198 3 days ago

1 contributor

4629 lines (4628 sloc) 596 KB Raw Blame History

Analyse des Einsatzes von Erschließungsstrategien beim Lesen

Am 2. 3. 2018 wurden an der Universität Valencia in zwei DaF-Gruppen (A2, B2) Daten zum wahrgenommenen Strategieneinsatz der Lernenden bei der Bearbeitung einer Aufgabe zum Lesen und Verstehen des neuen Wortschatzes erhoben. Die Studierenden wurden gebeten, beim Lesen eines Textes aus dem Lehrwerk zunächst alle für sie neuen Wörter zu markieren (unabhängig von deren Verständnis). Nach einem zweiten Lesedurchgang sollten sie diese in eine Liste eintragen und angeben, welche Strategien sie angewendet hätten, um deren Bedeutung zu erkennen. Ein Teil der Lernenden hatte zuvor (freiwillig) an der Befragung zum Thema Erschließungsstrategien für unbekannten Wortschatz im Deutschen durch Lernende an spanischen Universitäten teilgenommen (siehe: http://diarium.usal.es/martinakienberger/200-2/?lang=de). Für alle Studierenden wurde kurz das Thema erklärt und Beispiele für Strategien gegeben.

Vorbereitung - Datenreinigung

In [1]:
```
import pandas as pd
import numpy as np
from biofes import biplot
from sklearn.utils.extmath import randomized_svd
from sklearn.cluster import KMeans, AgglomerativeClustering
from adjustText import adjust_text
% pylab inline
```

```
Populating the interactive namespace from numpy and matplotlib
```

In [2]:
```
Rohdaten = pd.read_excel('D:\Daten\DISS\Daten\Valencia.xlsx')
```

In [3]:
```
Rohdaten.head(3)
```

2. Empezando a trabajar con Python

- Instalación

- Un entorno para programar

- Guardar y compartir los resultados

3. Un ejemplo: Mi proyecto de investigación

Estrategias de comprensión
para palabras desconocidas
en alemán

Descubro el significado o la función de palabras nuevas en alemán gracias a mi lengua materna. (L1)

Descubro el significado o la función de palabras nuevas en alemán con la ayuda de otras lenguas. (LE)

Utilizo mis conocimientos de alemán, p. ej. otras palabras conocidas, clases de palabras o la formación de palabras compuestas. (AL)

Nach Adelboden zur digitalen Entgiftung

BERN. Flugmodus für die Seele: Adelboden Tourismus eröffnet das erste Digital Detox Camp der Schweiz. Vier Tage lang werden die Besucher von Pushs und Whatsapp-Nachrichten abgeschirmt. Anstatt Surfen im Internet stehen Yoga und Entspannungsübungen auf dem Programm. Selfiesticks haben dabei nichts verloren, dafür werden in der Berghütte Freelax in Tronegg Bleistifte und Notizbücher verteilt. «Bei uns auf der Alp kann man Antworten auf die tägliche Hektik finden», sagt Tourismusdirektor Urs Pfenninger. Die Teilnehmer sollen in erster Linie wieder lernen, offline zu sein. Für diesen «kalten Entzug» stehen den Gästen Coaches zur Seite, die Teilnehmer auf eine Sinnesreise mitnehmen.

Doch das Camp vom 7. bis 10. September ist erst ein Experiment. Deshalb sucht Adelboden Tourismus derzeit nach fünf Freiwilligen, die sich dieser Challenge stellen. MIW

Yoga statt Whatsapp in den Bergen. DIGITALDETOX

Utilizo información extraída del contexto, p. ej. la posición de una palabra en la frase o el formato del texto. (Con)

Pido ayuda a mi profesor/a. (Prof)

Pido ayuda a mis compañeros/as de clase. (Co)

Consulto un diccionario u otra fuente (en papel o digital). (Dicc)

3. Mi proyecto de investigación

- ✓ El estudio:
  - 94 estudiantes de 5 cursos de alemán
    de 3 universidades españolas (Valencia, Salamanca, Granada)
  - Hojas de trabajo: palabras + estrategias (texto libre)
- ✓ Datos → Excel

2. 3. 2018, Valencia

Estrategias para comprender palabras desconocidas en alemán - un ejercicio

- Vas a leer un texto.
- Al leerlo por primera vez marca todas las palabras que no conoces aún (independientemente de si las entiendes por el contexto o no).
- Después, lee el texto por segunda vez y busca el significado de las palabras desconocidas. Seguramente lograrás entender algunas de estas palabras nuevas enseguida, otras después de pensar un poco. Si no encuentras el significado sin ayuda, puedes usar un diccionario o preguntar a otra persona.
- A continuación, apunta en esta hoja las palabras nuevas y las estrategias que has usado para averiguar su significado. También puedes indicar elementos del texto que han facilitado la comprensión de una palabra para ti.

Palabra nueva	*Estrategia(s) usada(s), indicios*

	A	B	C	D	E	F	G	H	I
1	Grupo	ID_alumno	Encuesta	Palabra	Estrategia_1	Estrategia_2	Estrategia_Esp_1	Estrategia_Esp_2	Comentario
2	A2	1	1	lebendiger	AL		Comp		
3	A2	1	1	langen	Con				
4	A2	1	1	eigene	Dicc				
5	A2	1	1	Lieder	AL				
6	A2	1	1	verwenden	Dicc				
7	A2	1	1	alltägliches	AL		Comp		
8	A2	1	1	Kommunikationsmittel	AL		Comp		
9	A2	1	1	hört	AL				
10	A2	1	1	besonders	Dicc				
11	A2	1	1	Färbung	Dicc				
12	A2	1	1	meistens	Dicc				
13	A2	1	1	klingt	Con				
14	A2	1	1	sondern	Dicc				
15	A2	1	1	Stadtsparkasse	Dicc				
16	A2	1	1	gegründet	Con				
17	A2	1	1	Geschenk	Dicc				
18	A2	1	1	bietet	Dicc				
19	A2	1	1	liere					
20	A2	1	1	echte	Dicc				
21	A2	1	1	Abschlusstest	Dicc				
22	A2	1	1	Zugezogene	Dicc				
23	A2	1	1	Kölsch-Abitur	Dicc				
24	A2	1	1	Außerdem	AL		Comp		
25	A2	1	1	Bibliothek	L1				
26	A2	1	1	Büchern	AL		Comp		
27	A2	1	1	Sammlung	Dicc				
28	A2	1	1	Bildern	Dicc				
29	A2	2	1	Kölsch	Con				
30	A2	2	1	lebendiger	Dicc				
31	A2	2	1	eigene	Con				

3. Mi proyecto de investigación

- ✓ El estudio:
  - 94 estudiantes de alemán de 5 cursos/asignaturas de lengua de 3 universidades españolas
  - Hojas de trabajo: palabras + estrategias (texto libre)
- ✓ Datos → Excel
- ✓ Importar datos en Jupyter
- ✓ Análisis
- ✓ Visualización

jupyter Datenanalyse_Voc_Valencia Last Checkpoint: 18.09.2018 (autosaved) Logout

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

Run Markdown

Vorbereitung - Datenreinigung

In [1]:
```
import pandas as pd
import numpy as np
from biofes import biplot
from sklearn.utils.extmath import randomized_svd
from sklearn.cluster import KMeans, AgglomerativeClustering
from adjustText import adjust_text
% pylab inline
```

```
Populating the interactive namespace from numpy and matplotlib
```

In [2]:
```
Rohdaten = pd.read_excel('D:\Daten\DISS\Daten\Valencia.xlsx')
```

In [3]:
```
Rohdaten.head(3)
```

Out[3]:

	Grupo	ID_alumno	Encuesta	Palabra	Estrategia_1	Estrategia_2	Estrategia_Esp_1	Estrategia_Esp_2	Comentario
0	A2	1	1	lebendiger	AL	NaN	Comp	NaN	NaN
1	A2	1	1	langen	Con	NaN	NaN	NaN	NaN
2	A2	1	1	eigene	Dicc	NaN	NaN	NaN	NaN

Entfernung ungeeigneter Antworten

In [4]:
```
Rohdaten.loc[117]
```

Out[4]:
```
Grupo                          A2
ID_alumno                       9
Encuesta                        2
Palabra                      Imis
Estrategia_1                  Con
Estrategia_2                  NaN
Estrategia_Esp_1    L1 = Deutsch!
Estrategia_Esp_2              NaN
Comentario                    NaN
Name: 117, dtype: object
```

In [5]:
```
Daten = Rohdaten.drop([117,372])
```

Als ungeeignet wurden ID 9 und ID 30 von der Analyse ausgeschlossen: ID 9 war Deutsch-Erstsprecher. ID 30 hatte die Aufgabe falsch verstanden und keine Strategien (sondern Übersetzungen) angegeben.

Auswahl der für die Analyse relevanten Teile der Erhebung

In [6]:
```
cols = ['Grupo','ID_alumno','Encuesta','Palabra','Estrategia_1','Estrategia_2']
```

In [7]:
```
data = Daten[cols]
```

In [8]:
```
data.loc[118]
```

Out[8]:
```
Grupo                  A2
ID_alumno              10
Encuesta                2
Palabra         lebendiger
Estrategia_1          Dicc
Estrategia_2           NaN
Name: 118, dtype: object
```

Analyse des Strategieneinsatzes

Unterteilung der beiden Gruppen

In [9]:
```
A2 = data[data.Grupo == 'A2']
```

In [10]:
```
B2 = data[data.Grupo == 'B2']
```

Gruppe A2

In [11]:
```
print(r'Teilnehmer: ' + str(len(A2.ID_alumno.unique()))+'\n'+
      r'TN + Online-Befragung: ' + str(len(A2[A2.Encuesta == 1].ID_alumno.unique()))+'\n'+
      r'TN - Online-Befragung: ' + str(len(A2[A2.Encuesta == 2].ID_alumno.unique()))+'\n'+
      r'TN ? Online-Befragung: ' + str(len(A2[A2.Encuesta == 0].ID_alumno.unique())))
```

```
Teilnehmer: 28
TN + Online-Befragung: 6
TN - Online-Befragung: 18
TN ? Online-Befragung: 4
```

Die Gruppe besteht aus 28 Teilnehmern. 6 hatten an der Online-Befragung teilgenommen, 18 nicht, 4 hatten keine Angabe dazu gemacht.

Als "neu" identifizierte Wörter (A2)

In [12]:
```
len(A2.Palabra.unique())
```

Out[12]: 47

47 unterschiedliche Wörter wurden von den Lernenden als für sie "neu" angegeben. Bei der Datenübertragung von den Aufgabenblättern in Excel wurden orthographische Fehler berichtigt. Die Wörter wurden in der jeweiligen Schreibung des Originaltextes aus dem Lehrbuch übernommen (auch wenn die Lernenden teilweise stattdessen eine andere Form, z.B. Infinitiv, angegeben hatten). Das Wort "bietet ... an" wurde zweimal aufgenommen, einmal als "bietet" und einmal als "bietet an", je nach Angabe der Lernenden, die das Wort offenbar teilweise nicht als trennbares Verb erkannt hatten.

In [13]:
```
A2.Palabra.value_counts(ascending = True).plot(kind = 'barh', figsize = (5,12));
```

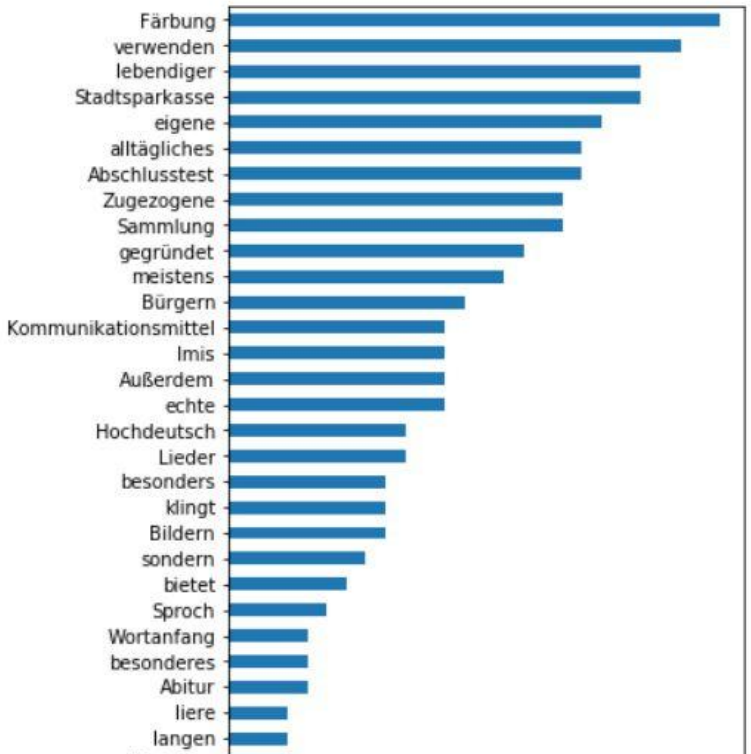

Kreuztabelle Studenten - neue Wörter (A2)

In [14]:
```
Al_Pal_A2 = pd.crosstab(A2.ID_alumno, A2.Palabra, margins = True)
```

In [15]:
```
Al_Pal_A2.T.head()
```

Out[15]:

ID_alumno	1	2	3	4	5	6	7	8	10	11	...	21	22	23	24	25	26	27	28	29	All
Palabra																					
Abitur	0	0	0	0	0	0	1	1	0	0	...	0	0	0	0	0	0	0	0	1	4
Abschlusstest	1	1	1	0	0	1	0	1	1	1	...	1	1	1	0	0	1	1	1	1	18
Akademie	0	0	0	0	0	0	0	0	0	0	...	0	0	0	1	0	0	0	0	0	1
Außerdem	1	0	0	0	0	1	0	1	0	0	...	0	1	1	0	0	0	0	0	1	11
Bibliothek	1	0	1	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	2

5 rows × 29 columns

In [16]:
```
print(r'Durchschnittlich als "neu" identifizierte Wortanzahl: '+str(Al_Pal_A2['All'][:-1].mean()))
```

```
Durchschnittlich als "neu" identifizierte Wortanzahl: 13.25
```

In [17]:
```
print(r'Minimum der als "neu" identifizierten Wörter: '+str(A2.ID_alumno.value_counts().min()) + '\n' +
      r'Maximum der als "neu" identifizierten Wörter: '+str(A2.ID_alumno.value_counts().max()))
```

```
Minimum der als "neu" identifizierten Wörter: 4
Maximum der als "neu" identifizierten Wörter: 27
```

Durchschnittlich wurden ca. 13 Wörter als "neu" identifiziert. Große Schwankungsbreite: zwischen 4 und 27 (siehe oben).

Einsatz von Erschließungsstrategien (A2) […]

In [20]:
```
v1 = A2.Estrategia_1.value_counts()
v2 = A2.Estrategia_2.value_counts()
```

In [21]:
```
v = v1 + v2
v['L1'] = v1['L1']
v['LE'] = v1['LE']
v['Co'] = v1['Co']
v
```

Out[21]:
```
AL       75.0
Co       31.0
Con      62.0
Dicc    177.0
L1       13.0
LE       11.0
Prof      5.0
dtype: float64
```

In [22]:
```
v.sort_values(ascending = False)
```

Out[22]:
```
Dicc    177.0
AL       75.0
Con      62.0
Co       31.0
L1       13.0
LE       11.0
Prof      5.0
dtype: float64
```

Da die Angaben einiger Studierender zwei Strategien zugeordnet werden können, müssen die Nennungen für die Gesamtauswertung zusammengezählt werden.

In [23]:
```
v.sort_values(ascending = False).plot(kind = 'bar',
                                      #title = 'Angaben zu eingesetzten Strategien',
                                      figsize = (10,6));
```

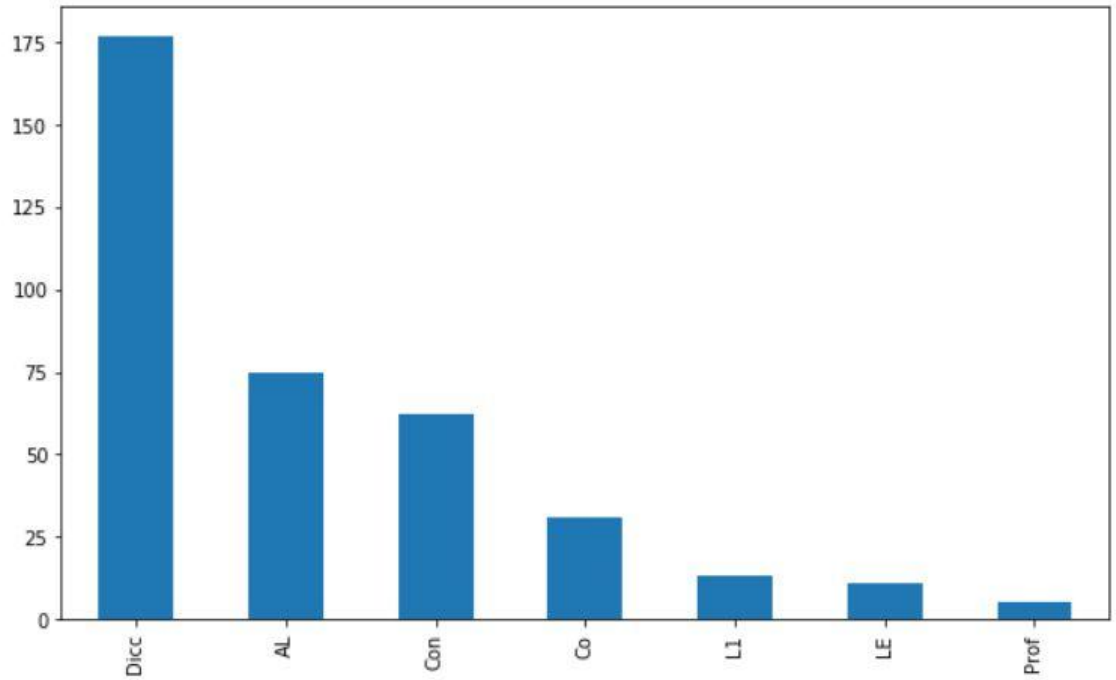

In [24]:
```
ax = v.sort_values(ascending = False).plot(kind = 'pie',
                                           #title = 'Angaben zu eingesetzten Strategien',
                                           figsize = (10,10),
                                           autopct='%.1f', startangle = -20);

ax.set_ylabel("");
```

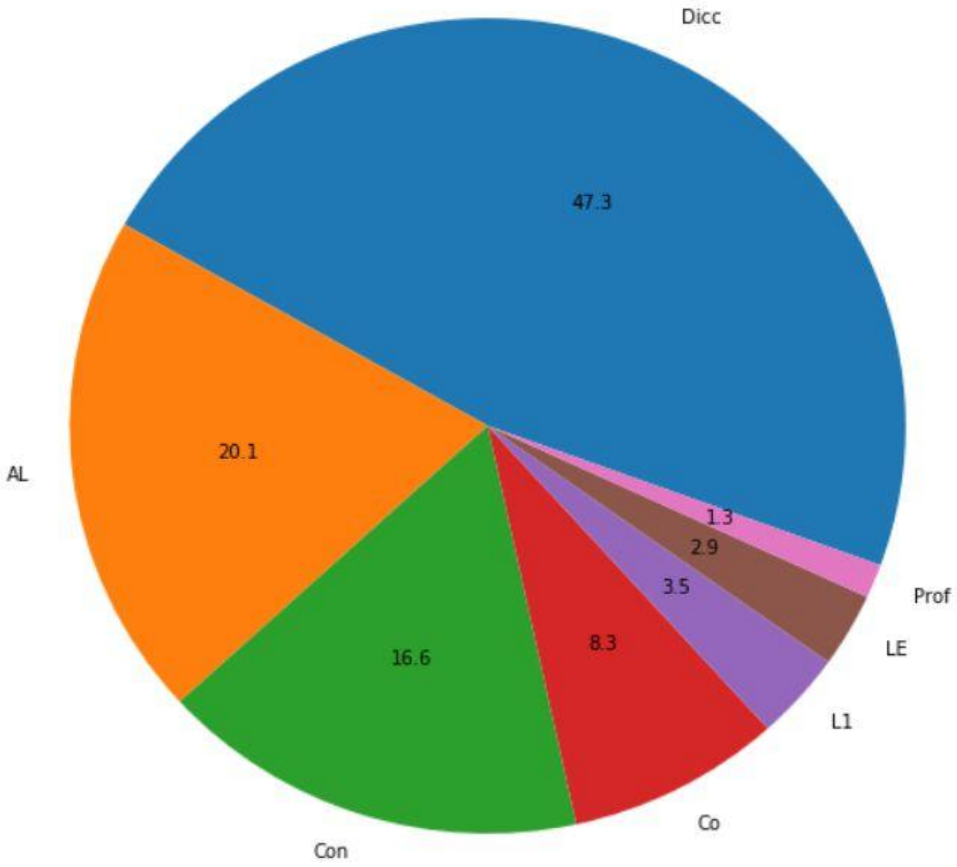

Kreuztabelle Studenten - verwendete Strategien (A2)

In [25]:
```
CTA2 = pd.crosstab(A2.ID_alumno, A2.Estrategia_1, margins = True)

CTA2_2 = pd.crosstab(A2.ID_alumno, A2.Estrategia_2, margins = True)
```

In [26]:
```
for val in CTA2_2.index:
    for col in CTA2_2.columns:
        if CTA2_2.loc[val,col]!=0:
            CTA2.loc[val,col] = CTA2.loc[val,col]+ CTA2_2.loc[val,col]
```

In [27]:
```
CTA2
```

Out[27]:

Estrategia_1	AL	Co	Con	Dicc	L1	LE	Prof	All
ID_alumno								
1	7	0	3	15	1	0	0	26
2	3	0	6	2	1	1	0	13
3	1	0	3	5	1	0	0	10
4	4	0	0	0	0	0	0	4
5	2	0	2	1	0	0	0	5
6	6	1	0	11	2	0	0	20
7	0	0	6	13	0	0	0	19
8	0	0	6	13	0	0	0	19
10	4	0	2	3	0	2	0	11
11	5	0	1	3	0	2	0	11
12	5	0	4	10	0	0	2	21
13	4	0	2	6	0	0	1	13
14	0	0	4	3	0	0	0	7

Korrespondenzanalyse und Biplot Studenten - verwendete Strategien (A2)

In [28]:
```
CA_A2L = biplot.CA(CTA2.values[:-1,:-1], 7, method = 1)
```

Mit den Daten der Kreuztabelle kann eine Korrespondenzanalyse durchgeführt werden, um die Beziehungen zwischen Elementen und Variablen grafisch repräsentieren zu können.

Eine Alternative stellt der Biplot dar, der besser geeignet ist, um Dimensionen der Darstellung zu reduzieren.

In [29]:
```
Biplot_A2L = biplot.Classic(CTA2.values[:-1,:-1], 7, method = 1)
```

In [30]:
```
R = Biplot_A2L.RowCoord
C = Biplot_A2L.ColCoord
cr = Biplot_A2L.RowCont
cc = Biplot_A2L.ColCont
```

Qualität der Repräsentation der Elemente und Variablen auf den Achsen des Biplots

In [31]:
```
Biplot_A2L.Inert
```

Out[31]:
```
array([ 27.4862713 ,  19.30682653,  16.16280832,  13.94912583,
         9.54467983,   7.89842503,   5.65186318])
```

Überblick über Informationsgehalt der einzelnen Achsen des Biplot (hier 7)

In [32]:
```
pd.DataFrame(cr, columns = ['Axis_'+str(el+1) for el in range(7)], index = CTA2.index[:-1])
```

Out[32]:

	Axis_1	Axis_2	Axis_3	Axis_4	Axis_5	Axis_6	Axis_7
ID_alumno							
1	7.812657	36.536490	6.926975	0.850467	27.001013	5.564122	15.308276
2	0.010366	0.699793	3.234423	45.925108	7.964813	14.725019	27.440478
3	18.657148	20.652116	16.126947	36.177166	7.638956	0.341211	0.406455
4	34.195345	0.177427	0.699517	0.075264	21.827818	41.760687	1.263942

In [34]:
```
fig = plt.figure(figsize=(10,10))
ax1 = fig.add_subplot(111)

ax1.scatter(R[:,0],R[:,1], s = 9)
for i in range(R.shape[0]):
    ax1.text(R[i,0],R[i,1], str(CTA2.index[:-1][i]), fontsize=12 )
for i in range(C.shape[0]):
    ax1.arrow(0,0,C[i,0],C[i,1])
    #ax1.scatter(C[i,0],C[i,1])
    ax1.text(C[i,0],C[i,1],CTA2.columns[:-1][i],fontsize=20)

plt.show()
```

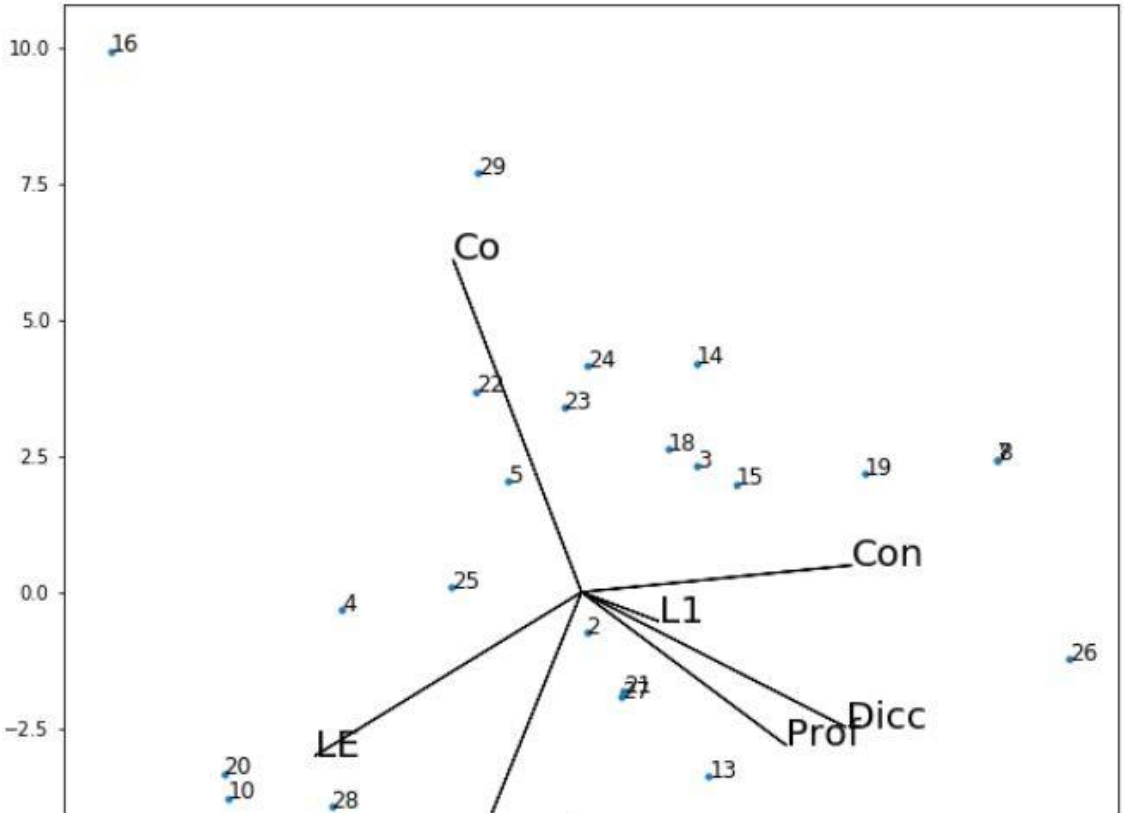

Cluster-Analyse Studenten - verwendete Strategien (A2)

Mit den Werten der Kreuztabelle können auch Cluster berechnet werden, um Gruppen differenzieren zu können.

Diese können in der Folge in einer Grafik mit den Ergebnissen des Biplots dargestellt werden.

In [35]:
```
#X = CTA2.values[:-1,:-1]
```

In [36]:
```
#kmeans = KMeans(n_clusters=5, random_state=0).fit(X)
ward = AgglomerativeClustering(n_clusters=5).fit(CTA2.values[:-1,:-1])
```

Beide Berechnungsarten führen zu ähnlichen Ergebnissen, in der Folge wird "ward" verwendet.

Tests mit unterschiedlicher Anzahl an Clustern zeigen, dass 5 sinnvolle Ergebnisse liefert.

Darstellung Biplot + Cluster

In [37]:
```
fig = plt.figure(figsize=(10,10))
ax = fig.add_subplot(111)

for i in range(C.shape[0]):
    ax.arrow(0,0,C[i,0],C[i,1], alpha = 0.7)
    #ax.scatter(C[i,0],C[i,1]) # Hier würden Linien nicht angezeigt.
    ax.text(C[i,0],C[i,1],CTA2.columns[:-1][i],fontsize=20, alpha = 0.7)

ax.scatter(R[:,0],R[:,1], s = 12, c = ward.labels_)
texts = [plt.text(R[i,0],R[i,1], CTA2.index[:-1][i], ha='center', va='center') for i in range(len(R[:,0
]))]
adjust_text(texts);
```

In [38]:
```
def vector_to_shape(v):
    markers = ["," , "o" , "v" , "^", "x", "D", "*"]
    return [markers[el] for el in v]
```

In [39]:
```
def vector_to_color(v):
    col = ['b', 'g', 'r', 'c', 'm', 'k', 'y']
    return [col[el] for el in v]
```

In [40]:
```
def graf_cplot(data, dim, nclust, dim1 = 0, dim2 = 1, sx = 10, sy = 10):

    B = biplot.Classic(data, dim, method = 1)
    R = B.RowCoord
    C = B.ColCoord

    ward = AgglomerativeClustering(n_clusters=nclust).fit(data)

    fig = plt.figure(figsize=(sx,sy))
    ax = fig.add_subplot(111)

    sh_v = vector_to_shape(ward.labels_)
    color_v = vector_to_color(ward.labels_)

    for i in range(C.shape[0]):
        ax.arrow(0,0,C[i,dim1],C[i,dim2], alpha = 0.7)
        #ax.scatter(C[i,dim1],C[i,dim2]) # Hier würden Linien nicht angezeigt.
        ax.text(C[i,dim1],C[i,dim2],data.columns[i],fontsize=20, alpha = 0.7)

    for i in range(R.shape[0]):
        ax.scatter(R[i,dim1],R[i,dim2], s = 20, c = color_v[i] ,marker = sh_v[i])

    texts = [plt.text(R[i,dim1],R[i,dim2], data.index[i], ha='center', va='center') for i in range(len(R
[:,0]))]
    adjust_text(texts);
```

```
In [42]: graf_cplot(CTA2.iloc[:-1,:-1], 7, 5)
```

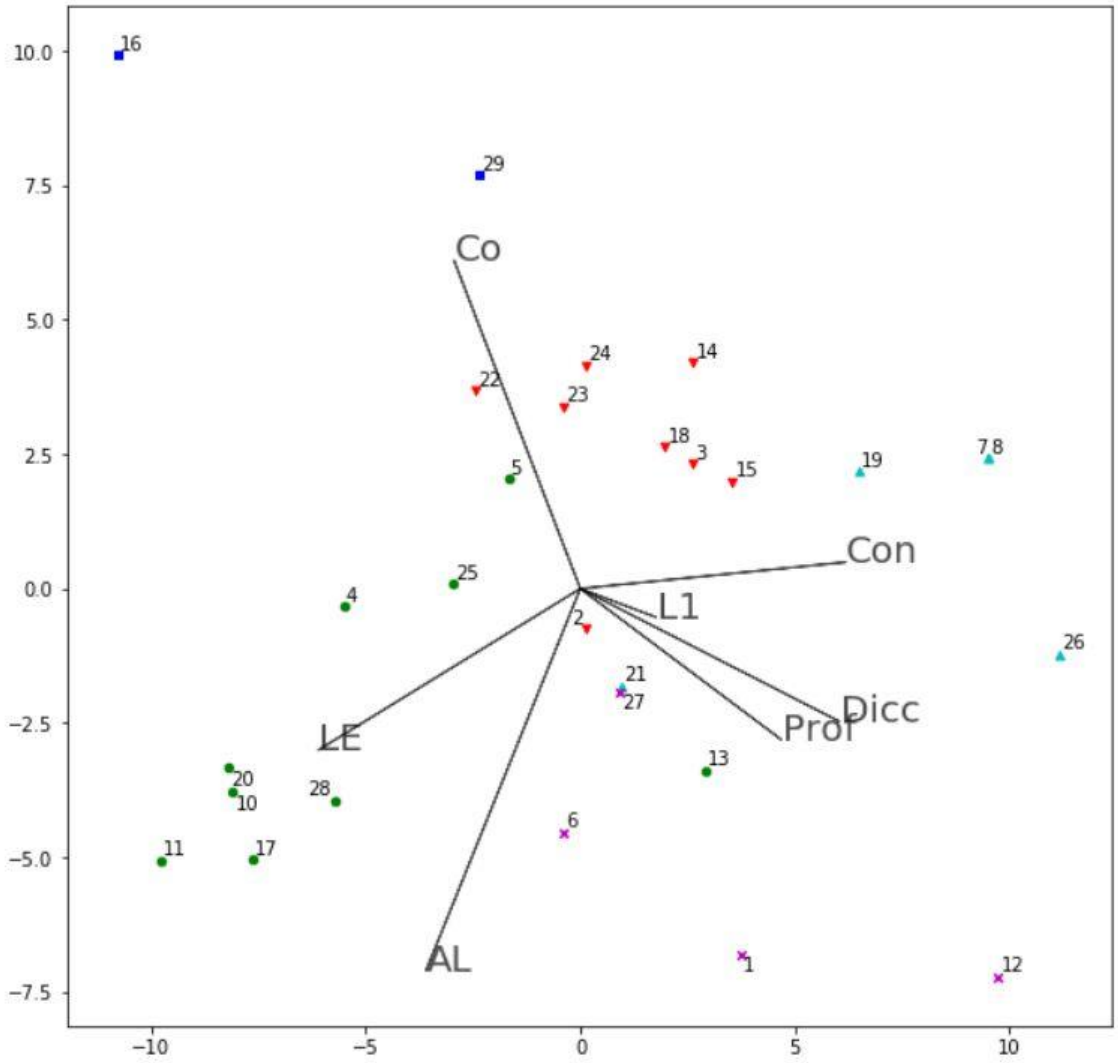

Kreuztabelle Wörter - verwendete Strategien (A2)

In [43]:
```
Pal_Es_A2 = pd.crosstab(A2.Palabra, A2.Estrategia_1, margins = True)
Pal_Es_A2_2 = pd.crosstab(A2.Palabra, A2.Estrategia_2, margins = True)
```

In [44]:
```
for val in Pal_Es_A2_2.index:
    for col in Pal_Es_A2_2.columns:
        if Pal_Es_A2_2.loc[val,col]!=0:
            Pal_Es_A2.loc[val,col] = Pal_Es_A2.loc[val,col]+ Pal_Es_A2_2.loc[val,col]
```

In [45]:
```
Pal_Es_A2.sort_values(['All'], ascending=[0])
```

Out[45]:

Estrategia_1	AL	Co	Con	Dicc	L1	LE	Prof	All
Palabra								
All	75	31	62	177	13	11	5	374
Färbung	9	3	2	10	0	0	2	26
Stadtsparkasse	11	2	3	6	1	1	0	24
verwenden	0	2	7	14	0	0	0	23
lebendiger	9	2	1	10	0	0	0	22
eigene	0	1	5	14	0	0	0	20
alltägliches	7	2	3	5	0	0	1	18
Abschlusstest	7	0	0	11	0	0	0	18
Sammlung	0	1	7	8	1	0	0	17
gegründet	2	1	3	9	0	0	0	15
Zugezogene	0	4	1	9	0	0	0	14
meistens	0	3	0	11	0	0	0	14
Bürgern	1	0	0	10	0	2	0	13

```
In [50]: graf_cplot2(Pal_Es_A2.iloc[:-1,:-1],7, 4)
```

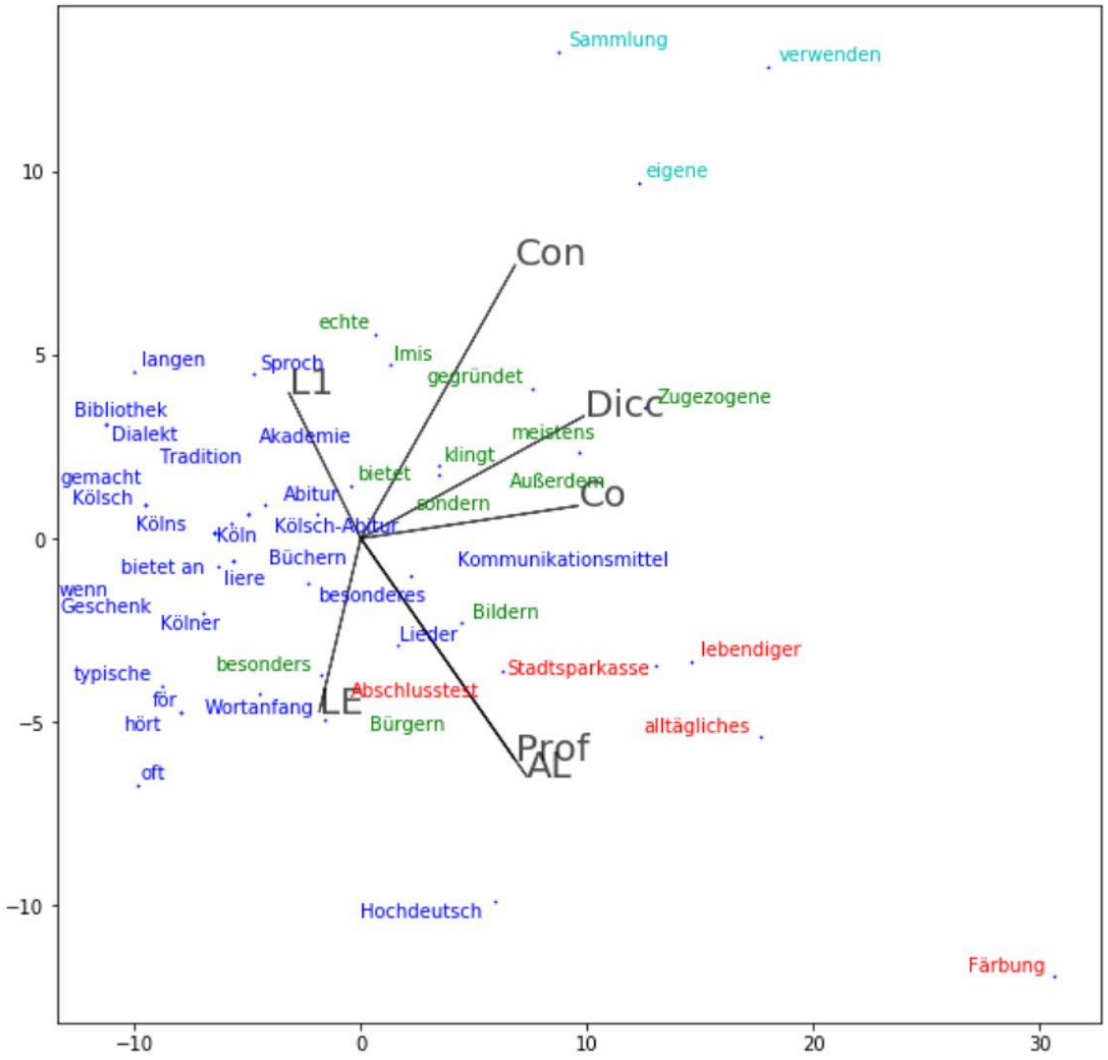

4. Algunas estrategias de aprendizaje

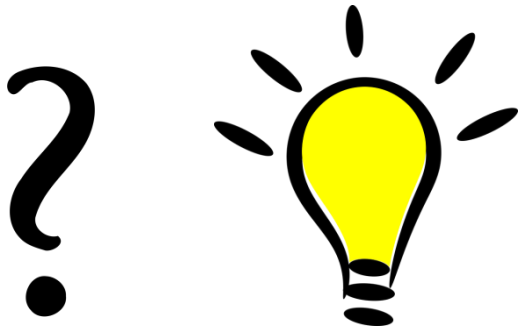

4. Algunas estrategias de aprendizaje

- ✓ Aprender lo básico con un tutorial o libro de introducción
- ✓ Utilizar recursos online:
  - Páginas web de apoyo para principiantes
  - Documentación de las librerías
  - Foros (Stack Overflow)
- ✓ Ver ejemplos
- ✓ Aprender de tus errores

Vorbereitung - Datenreinigung

In [1]:
```
import pandas as pd
import numpy as np
from biofes import biplot
from sklearn.utils.extmath import randomized_svd
from sklearn.cluster import KMeans, AgglomerativeClustering
from adjustText import adjust_text
% pylab inline
```

```
Populating the interactive namespace from numpy and matplotlib
```

In [2]:
```
Rohdaten = pd.read_excel('D:\Daten\DISS\Daten\Valencia.xlsx')
```

In [1]:
```
Rohdaten.head(3)
```

```
---------------------------------------------------------------------------
NameError                                 Traceback (most recent call last)
<ipython-input-1-c9831417dbd0> in <module>()
----> 1 Rohdaten.head(3)

NameError: name 'Rohdaten' is not defined
```

In [5]:
```
Rohdaten.head.
```

```
  File "<ipython-input-5-e52ee1ca942f>", line 1
    Rohdaten.head.
                  ^
SyntaxError: invalid syntax
```

4. Algunas estrategias de aprendizaje

- ✓ Aprender lo básico con un tutorial o libro de introducción
- ✓ Utilizar recursos online:
  - Páginas web de apoyo para principiantes
  - Documentación de las librerías
  - Foros (Stack Overflow)
- ✓ Ver ejemplos
- ✓ Aprender de tus errores
- ✓ Empezar con lo básico + variar
- ✓ Buscar ayuda, preguntar

Referencias

Morais, M. & Pillai, S. R. (2017). Data Analysis for Social Science and Marketing Research Using Python: A Non-Programmer's Guide. Aspire Analytic Solutions.

Caren, N. (2018). Learning Python for Social Scientists. En: https://nealcaren.github.io/python-tutorials/ (inglés)

Klein, B. (2017). Python-Kurs. En: www.python-kurs.eu/index.php (alemán)

Muller, R. (2018). A Crash Course in Python for Scientists. En: http://nbviewer.jupyter.org/gist/rpmuller/5920182 (inglés)

Contacto:

martina.kienberger@usal.es

http://diarium.usal.es/martinakienberger/

https://github.com/martinakienberger